Исследование предоставленных захватов

Английский оригинал: DATASET_INVESTIGATION.md.

Набор захватов организатора нормализуется тем же путём, что использует приложение (`src/capture/pipeline.py`), и читается обратно через контракт захвата, поэтому эти числа описывают поставляемые файлы и поставляемый код, а не фикстуру.

1. Исследовательские захваты

Правило запроса (`examples/thermostand_request_v2.json`) и правило ответа (`examples/thermostand_response_v2.json`) применяются к каждому исследовательскому захвату. `not_applicable` считает сообщения, которые несёт другое направление, поэтому чистый захват сообщает только `matched`.

Запросы:

захват	matched	mismatched	incomplete	not_applicable
01_configuration.pcap	14	0	0	14
02_variations.pcapng	15	0	0	15
03_combined_messages.pcap	8	0	0	8
04_new_observations.pcapng	8	0	0	8

Ответы:

захват	matched	mismatched	incomplete	not_applicable
01_configuration.pcap	14	0	0	14
02_variations.pcapng	15	0	0	15
03_combined_messages.pcap	8	0	0	8
04_new_observations.pcapng	8	0	0	8

Ни одно сообщение не mismatched, incomplete или ambiguous ни в одном исследовательском захвате. Два исключения в потоке ответов захвата вариаций — ответы об ошибках (`value_out_of_range`, `malformed_body`): они несут однобайтовое тело, поэтому поля конфигурации после статуса корректно вне сообщения, и поля, принадлежащие успешному ответу, не применяются.

2. Уточнение по контрпримеру

Первое чтение (`examples/thermostand_request_v1.json`) предполагает, что поле длины считает только нагрузку и что сообщение начинается с первого байта поля длины. Применённое к захвату конфигурации:

правило	matched	mismatched	incomplete
v1 (длина только нагрузки)	0	2	4
v2 (длина включает четырёхбайтовый заголовок)	14	0	0

Контрпримеры, которые производит v1, каждый привязан к своим байтам:

статус	поле	причина
incomplete	message_counter	field_beyond_message
mismatched	magic	value 1 not in expected [42588]
incomplete	magic	payload_truncated
incomplete	message_counter	field_beyond_message
mismatched	magic	value 1 not in expected [42588]
incomplete	magic	payload_truncated

Исправление — четырёхбайтовое смещение заголовка во фрейминге длины, которое v2 несёт как `length_bias`. Контрпримеры — это доказательство: первое сообщение под v1 сфреймлено на четыре байта короче, поэтому магия читается по неверному смещению, а счётчик попадает вне сообщения.

3. Диагностические захваты

Каждый диагностический захват построен, чтобы упражнять один режим отказа. Диагностики ниже — то, что пересборщик действительно сообщает.

захват	упражняет	сообщённые диагностики
01_retransmission.pcap	ретрансмиссию	нет
02_reordered.pcapng	доставку не по порядку	нет
03_missing_segment.pcap	недостающий сегмент	gap
04_snaplen_truncated.pcapng	обрезанный снимок	gap
05_conflicting_overlap.pcap	конфликтующее перекрытие	ambiguity
06_missing_beginning.pcapng	соединение без начала	нет
07_checksum_offload.pcap	checksum offloading	нет
08_bad_checksum.pcapng	неверную контрольную сумму	нет

Проверка контрольных сумм выключена по умолчанию, поэтому `07_checksum_offload.pcap` сообщает `none`. С `--verify-checksums` он сообщает `checksum_offload`.

4. Корреляция с журналом

Журнал действий держит 109 записей. Раскодированные запросы коррелируются так: 14 из 14 сообщений скоррелированы, 95 записей журнала не сопоставлены

Корреляция привязывает каждое сообщение-запрос к выполняемому им действию оператора и подтверждает раскодированные параметры по записанным значениям, так что имя поля — не просто правдоподобная метка.

5. Откуда берётся набор

Состав и происхождение данных записаны организатором в `tests/corpus/real/dataset_manifest.json`: ожидаемые счётчики сессий и действий на исследовательский захват и утверждение, что байты приложения приходят из реального TCP-обмена клиента/симулятора

через сокет, тогда как фрейминг Ethernet/IP/TCP, сегментация и часы сгенерированы. Конвейер воспроизводит записанные счётчики сессий (2, 1, 1, 1) точно, а восемь диагностических захватов несут каждый одно условие захвата или целостности. Полный анализ — в `docs/REAL_CORPUS_ANALYSIS.md`.