Анализ реального корпуса: набор организатора

Английский оригинал: REAL_CORPUS_ANALYSIS.md.

Организатор предоставил набор захватов для протокола «термостенд». Он закоммичен в `tests/corpus/real/` и разобран тем же конвейером, что использует приложение, поэтому эти числа описывают поставляемые файлы и поставляемый код. Сгенерированный отчёт — `docs/DATASET_INVESTIGATION.md`; команда воспроизведения — `python -m scripts.investigate_dataset`.

1. Что содержит набор

Файл	Роль
`research/01_configuration.pcap`	изменения конфигурации и измерения, две TCP-сессии
`research/02_variations.pcapng`	другие настройки, отрицательные температуры, метки нескольких длин, кириллица, отвергнутые запросы
`research/03_combined_messages.pcap`	несколько действий в одной отправке клиента, разные разбиения на пакеты
`additional/04_new_observations.pcapng`	второй эксперимент с другими значениями и размерами пакетов
`diagnostics/01..08`	варианты третьей записи, каждый с одним условием захвата или целостности
`action_journal.csv`	109 действий с параметрами, временем и результатом, который показал клиент
`dataset_manifest.json`	состав набора и происхождение данных

Собственный `README_RU.md` организатора указывает происхождение: байты приложения приходят из реального TCP-обмена клиента/симулятора через сокет на localhost, тогда как фрейминг Ethernet/IP/TCP, сегментация и часы сгенерированы. Набор — проверка функций протокола, а не пассивный захват устройства.

`dataset_manifest.json` записывает ожидаемые счётчики сессий и действий на исследовательский захват. Конвейер воспроизводит счётчики сессий точно.

2. Сессии и потоки

Захват	Сессий	Байт потока	Действий журнала
`research/01_configuration.pcap`	2	443	14
`research/02_variations.pcapng`	1	608	15
`research/03_combined_messages.pcap`	1	358	8
`additional/04_new_observations.pcapng`	1	384	8
итого	5	1793	45

Счётчики сессий совпадают с `dataset_manifest.json` (2, 1, 1, 1).

3. Фрейминг сообщений и правила

Протокол описывают два правила: `examples/thermostand_request_v2.json` (направление `A_to_B`) и `examples/thermostand_response_v2.json` (направление `B_to_A`). Оба используют кадр с префиксом длины, чьё двухбайтовое поле длины считает четырёхбайтовый заголовок, что несётся как `length_bias: 4`.

Направление	Сообщений	matched	mismatched	incomplete	ambiguous	uncovered
запросы	45	45	0	0	0	0
ответы	45	45	0	0	0	0

Каждое сообщение в исследовательских захватах сфреймлено и совпадает, покрывая 100 % байт в обоих направлениях. Счётчик `not_applicable` в отчёте правила — трафик другого направления, что ожидаемо.

По захватам

Захват	Сообщений-запросов	Сообщений-ответов
`01_configuration`	14	14
`02_variations`	15	15
`03_combined_messages`	8	8
`04_new_observations`	8	8

4. Определённые поля

Поле	Тип	Смещение (запрос / ответ)	Заметка
`magic`	uint16	0 / 0	константа `0xa65c` (42588)
`body_length`	uint16	2 / 2	считает четырёхбайтовый заголовок
`message_counter`	uint16	4 / 4	прирастает на каждый обмен
`message_type`	enum	6 / 6	запрос 16/32/48/126, ответ 272/288/304/382
`status`	enum	— / 8	0 ok, 1..4 коды ошибок
`enabled`	uint8	8 / 9	гипотеза, set-config и ответы config
`period_ms`	uint16	9 / 10	гипотеза
`threshold_raw`	int16	11 / 12	гипотеза
`label`	string	14 / 15	гипотеза, длина в предшествующем uint8
`requested_count`	uint8	8 / —	запрос read-values
`measurement_count`	uint8	— / 9	число записей измерений
`device_time_ms`	array uint32	— / 10	гипотеза, шаг 7
`temperature_raw`	array int16	— / 14	гипотеза, шаг 7; масштаб 0.01 °C
`alarm`	array uint8	— / 16	гипотеза, шаг 7

Значения enum были сверены с журналом: каждый раскодированный `message_type` соответствует действию, которое журнал записывает в то же время.

5. Контрпримеры и уточнение

Первое чтение, `examples/thermostand_request_v1.json`, предполагает, что поле длины считает только нагрузку. На захвате конфигурации оно производит шесть контрпримеров: первое сообщение сфреймлено на четыре байта короче, поэтому `magic` читается по неверному смещению, а `message_counter` попадает вне сообщения.

Правило	matched	mismatched	incomplete
v1 (длина только нагрузки)	0	5	10
v2 (длина включает заголовок)	45	0	0

Исправление — четырёхбайтовое смещение заголовка (`length_bias: 4`), которое несёт v2. Контрпримеры — это доказательство; они сохраняются в исследовании, а не отбрасываются.

6. Диагностики

Каждый диагностический захват построен, чтобы упражнять одно условие. Таблица — то, что пересборщик действительно сообщает.

Захват	Условие	Сообщено
`01_retransmission`	ретрансмиссия тех же байтов	дедуплицировано (одна ретрансмиссия записана в `B_to_A`, без дублирующих байтов)
`02_reordered`	переупорядоченные пакеты	собрано в порядке последовательности, без пропуска
`03_missing_segment`	недостающий сегмент	`gap`
`04_snaplen_truncated`	обрезанный снимок	`gap`
`05_conflicting_overlap`	конфликтующее перекрытие	`ambiguity`
`06_missing_beginning`	нет начала соединения	`syn_seen=False`, роли последовательности UNKNOWN, поток всё равно построен
`07_checksum_offload`	частичная контрольная сумма псевдозаголовка	`checksum_offload`, когда проверка включена
`08_bad_checksum`	неверная контрольная сумма	`checksum_offload`, когда проверка включена

Проверка контрольных сумм выключена по умолчанию из-за offloading; последние две строки появляются только с `ignore_checksums=False`.

7. Корреляция с журналом

Журнал действий держит 109 записей. Применение правила запроса к захвату конфигурации и корреляция с журналом даёт:

```
14 of 14 messages correlated, 95 journal entries unmatched
```

Каждое раскодированное сообщение-запрос отображается на выполняемое им действие оператора, а раскодированные параметры согласуются с записанными значениями. Несопоставленные записи принадлежат другим захватам, которые не были частью того прогона корреляции.

8. Сравнение с синтетическим корпусом

Свойство	Синтетический корпус	Набор организатора
Происхождение	сгенерирован от начала до конца	байты приложения из реального сокета, фрейминг сгенерирован
Протокол	кадр с префиксом длины, ведущий `0x01`	магия `0xa65c`, длина, считающая заголовок
Исследовательские захваты	1 основной + 1 отложенный	3 исследовательских + 1 дополнительный
Захваты дефектов	1 объединённый	8, по одному условию каждый
Сообщений	280 сфреймленных	90 (45 + 45)
Исход правила	v1 даёт 80 контрпримеров, v2 их убирает	v1 даёт 6 контрпримеров, v2 их убирает

Оба корпуса упражняют один и тот же цикл уточнения: наивное правило, контрпримеры, привязанные к байтам, версионированное исправление и чистая проверка после него. Набор организатора добавляет более тонкое покрытие дефектов (восемь захватов с одним условием) и второй, независимый протокол с другим соглашением фрейминга.

9. Применимость и ограничения

- Правила подтверждены на 90 сообщениях по четырём захватам, а не доказаны. Организатор утверждает, что заголовки фрейминга сгенерированы, поэтому поведение уровня заголовков, видимое здесь, следует перепроверить на пассивном захвате.
- `temperature_raw` — гипотеза с масштабом 0.01 °C; положительность масштаба опирается на значения журнала, а не на байтовый инвариант.
- Массивы измерений используют фиксированный шаг в семь байт; запись другой длины сообщалась бы как `incomplete`, а не молча прочиталась неверно.
- Ответы об ошибках несут однобайтовое тело, поэтому поля конфигурации после `status` корректно вне сообщения.

10. Как воспроизвести

```
python -m scripts.investigate_dataset          # пишет docs/DATASET_INVESTIGATION.md
pytest tests/hypothesis/test_real_corpus.py -v # сквозные проверки
```